



高维统计笔记

作者：Crab

时间：2025 年 1 月 3 日

说明：本笔记根据王成、刘卫东老师翻译的 Martin J. Wainwright
《High-Dimensional Statistics: A Non-Asymptotic Viewpoint》整理而成



I don't have any secret. I'm just passionate about what I do. —Samuelson

目 录

第 1 章 简介	1
1.1 经典理论和高维理论	1
1.2 高维会产生什么问题	1
1.3 高维中什么能帮助我们	1
1.4 什么是非渐进的观点	1
1.5 全书概述	1
第 2 章 基本尾部概率界和集中不等式	2
2.1 经典的界	2
2.1.1 从马尔可夫不等式到 Chernoff 界	2
2.1.2 次高斯随机变量和 Hoeffding 界	2
2.1.3 次指数随机变量和 Bernstein 界	4
2.1.4 一些单边结果	5
2.2 基于鞅的方法	6
2.2.1 背景	6
2.2.2 鞅差序列的集中度界	7
2.3 高斯随机变量的 Lipschitz 函数	10
2.4 附录 A: 次高斯随机变量的等价性	11
2.5 附录 B: 次指数随机变量的等价性	11
第 3 章 测度集中度	12
3.1 基于熵技巧的集中度	12
3.1.1 熵及其相关性质	12
3.1.2 Herbst 方法及其延伸	12
3.1.3 可分凸函数和熵方法	13
3.1.4 张量化和可分凸函数	14
3.2 集中度的几何观点	15
3.2.1 集中度函数	15
3.2.2 与 Lipschitz 函数的联系	16
3.2.3 从几何到集中度	16
3.3 Wasserstein 距离和传输成本不等式	16
3.3.1 Wasserstein 距离	16
3.3.2 传输成本和集中不等式	17
3.3.3 传输成本的张量化	18

3.3.4	马尔可夫链的传输成本不等式	19
3.3.5	非对称耦合成本	19
3.4	经验过程的尾部概率界	20
3.4.1	一个泛函 Hoeffding 不等式	20
3.4.2	一个泛函 Bernstein 不等式	20
第 4 章	一致大数定律	21
第 5 章	2024 高维期末范围	22
附录 A	常用分布表	27
索 引		29
参考文献		30

第 1 章 简介

1.1 经典理论和高维理论

1.2 高维会产生什么问题

内容提要

- 线性判别分析
- 非参数回归
- 协方差估计

1.3 高维中什么能帮助我们

我们期望数据具有一定的低维结构，这使得我们能够简化高维问题。

内容提要

- 向量的稀疏性
- 回归形式的结构
- 协方差矩阵中的结构

1.4 什么是非渐进的观点

1.5 全书概述

- 工具和方法：第 2-5 章、第 12 章、第 14-15 章
- 模型和估计：第 6-11 章、第 13 章

第 2 章 基本尾部概率界和集中不等式

2.1 经典的界

2.1.1 从马尔可夫不等式到 Chernoff 界

- 马尔可夫不等式：对任意一个均值有限的非负随机变量 X ，有

$$\mathbb{P}[X \geq t] \leq \frac{\mathbb{E}[X]}{t}, \quad \forall t > 0. \quad (2.1)$$

- Chebyshev 不等式：如果这个随机变量 X 还有有限的方差，则有

$$\mathbb{P}[|X - \mu| \geq t] \leq \frac{\text{Var}(X)}{t^2}, \quad \forall t > 0. \quad (2.2)$$

- Chernoff 界：若随机变量 X 在 0 的领域 $[0, b]$ 内有矩母函数，则有

$$\mathbb{P}[(X - \mu) \geq t] \leq \inf_{\lambda \in [0, b]} \frac{\mathbb{E}[e^{\lambda(X - \mu)}]}{e^{\lambda t}} \quad (2.3)$$

注 一般情况下，马尔可夫不等式和 Chebyshev 不等式所给的界是最优的。

2.1.2 次高斯随机变量和 Hoeffding 界

例 2.1 (次高斯尾部界)

对于随机变量 $X \sim \mathcal{N}(\mu, \sigma^2)$ ，有上偏差不等式：

$$\mathbb{P}[X \geq \mu + t] \leq \exp\left(-\frac{t^2}{2\sigma^2}\right), \quad \forall t \geq 0. \quad (2.4)$$

注 事实上，根据对 Mills 比的探究，这个界是除了多项式修正项之外最优的。

定义 2.1 (次高斯随机变量)

设随机变量 X 的均值 $\mu = \mathbb{E}[X]$ ，若存在 $\sigma > 0$ ，使得

$$\mathbb{E}[e^{\lambda(X - \mu)}] \leq \exp\left\{\frac{\sigma^2 \lambda^2}{2}\right\}, \quad \forall \lambda \in \mathbb{R}, \quad (2.5)$$

则称这个随机变量 X 是次高斯 (sub-Gaussian) 的，常数 σ 称为次高斯参数。

将上偏差不等式和下偏差不等式结合，可以得到对任意次高斯随机变量 X 的集中不等式：

$$\mathbb{P}[|X - \mu| \geq t] \leq 2 \exp\left(-\frac{t^2}{2\sigma^2}\right), \quad \forall t \in \mathbb{R}. \quad (2.6)$$

例 2.2 (Rademacher 随机变量)

一个 Rademacher 随机变量 ε 是指等概率地取 $\{-1, 1\}$ 的随机变量，它是一个参数为

$\sigma = 1$ 的次高斯随机变量。利用指数函数的级数展开，有

$$\begin{aligned}\mathbb{E}[e^{\lambda \varepsilon}] &= \frac{1}{2}\{e^{-\lambda} + e^{\lambda}\} = \frac{1}{2}\left\{\sum_{k=0}^{\infty} \frac{(-\lambda)^k}{k!} + \sum_{k=0}^{\infty} \frac{(\lambda)^k}{k!}\right\} \\ &= \sum_{k=0}^{\infty} \frac{\lambda^{2k}}{(2k)!} \leq 1 + \sum_{k=1}^{\infty} \frac{\lambda^{2k}}{2^k k!} = e^{\lambda^2/2}.\end{aligned}$$

例 2.3 (有界随机变量的次高斯性)

设 X 是均值为 0，支撑集为某个区间 $[a, b]$ 的随机变量。利用对称化技巧，可以证明 X 是一个次高斯随机变量，其中参数 σ 至多为 $b - a$ 。（实际上可以提升为 $\frac{b-a}{2}$ ）

$$\begin{aligned}\mathbb{E}_X[e^{\lambda X}] &= \mathbb{E}_X[e^{\lambda(X - \mathbb{E}_{X'}[X'])}] \leq \mathbb{E}_{X, X'}[e^{\lambda(X - X')}] \\ &= \mathbb{E}_{X, X'}[\mathbb{E}_\varepsilon[e^{\lambda \varepsilon(X - X')}]] \stackrel{(i)}{\leq} \mathbb{E}_{X, X'}[e^{\frac{\lambda^2(X - X')^2}{2}}] \leq e^{\frac{\lambda^2(b-a)^2}{2}}.\end{aligned}$$

其中步骤 (i) 是先固定 (X, X') 取条件期望得到。

注 例 2.3 中所用的是对称化技巧的一个简单例子：先引入一个和 X 独立同分布的 X' ，然后用一个 Rademacher 随机变量把问题对称化。

命题 2.1 (Hoeffding 界)

设次高斯随机变量 X_i 相互独立，对应的均值和次高斯参数分别为 μ_i, σ_i ，则对 $\forall t \geq 0$ ，有

$$\mathbb{P}\left[\sum_{i=1}^n (X_i - \mu_i) \geq t\right] \leq \exp\left(-\frac{t^2}{2 \sum_{i=1}^n \sigma_i^2}\right). \quad (2.7)$$

其中用到如下性质：

性质 设 X_1, X_2 是独立的次高斯随机变量，对应的参数分别为 σ_1, σ_2 ，则 $X_1 + X_2$ 是参数为 $\sqrt{\sigma_1^2 + \sigma_2^2}$ 的次高斯随机变量。

对次高斯随机变量的以下三种不同形式的刻画是等价的：

1. 通过计算矩母函数或得到矩母函数的界直接验证次高斯性；
2. 任意的次高斯随机变量在某种意义下会被一个正态随机变量控制；
3. 次高斯性可以通过控制随机变量的矩来得到。

定理 2.2 (次高斯随机变量定义的等价性)

对任意均值为 0 的随机变量 X ，下面的性质是等价的：

(I) 存在常数 $\sigma \geq 0$ 使得

$$\mathbb{E}[e^{\lambda X}] \leq \exp\left(\frac{\lambda^2 \sigma^2}{2}\right), \quad \forall \lambda \in \mathbb{R}.$$

(II) 存在常数 $c \geq 0$ 和正态随机变量 $Z \sim \mathcal{N}(0, \tau^2)$ 使得

$$\mathbb{P}[|X| \geq s] \leq c \mathbb{P}[|Z| \geq s], \quad \forall s \geq 0.$$

(III) 存在常数 $\theta \geq 0$ 使得

$$\mathbb{E}[X^{2k}] \leq \frac{(2k)!}{2^k k!} \theta^{2k}, \quad \forall k = 1, 2, \dots$$

(IV) 存在常数 $\sigma \geq 0$ 使得

$$\mathbb{E}[e^{\frac{\lambda X^2}{2\sigma^2}}] \leq \frac{1}{\sqrt{1-\lambda}}, \quad \forall \lambda \in [0, 1).$$

2.1.3 次指数随机变量和 Bernstein 界

次高斯的定义相对比较严格，考虑一些更为宽泛的情形。

定义 2.2 (次指数随机变量)

对于一个均值为 $\mu = \mathbb{E}[X]$ 的随机变量 X ，如果存在非负参数对 (ν, α) 满足

$$\mathbb{E}[e^{\lambda(X-\mu)}] \leq \exp\left(\frac{\nu^2 \lambda^2}{2}\right), \quad \forall |\lambda| < \frac{1}{\alpha}. \quad (2.8)$$

则称该随机变量是次指数 (sub-exponential) 的。

次高斯随机变量都是次指数的，但次指数随机变量不一定是次高斯的。

类似次高斯性，次指数随机变量也有相应的偏差和集中不等式。当 t 充分小的时候，这些界本质上是次高斯的（指数部分为 t^2 阶）；而当 t 较大的时候，这个界的指数部分会与 t 呈线性关系。

命题 2.3 (次指数尾部不等式)

设 X 是参数为 (ν, α) 的次指数随机变量，则

$$\mathbb{P}[X - \mu \geq t] \leq \begin{cases} e^{-\frac{t^2}{2\nu^2}}, & 0 \leq t \leq \frac{\nu^2}{\alpha}, \\ e^{-\frac{t}{2\alpha}}, & t > \frac{\nu^2}{\alpha}. \end{cases} \quad (2.9)$$

次指数性可以通过计算矩母函数或得到矩母函数的界来验证，但在许多情形下，这种直接计算的方法是不可行的，其中一种替代方法是控制 X 的多项式形式的矩。

给定均值为 $\mu = \mathbb{E}[X]$ ，方差为 $\sigma^2 = \mathbb{E}[X^2] - \mu^2$ 的随机变量 X ，称参数为 b 的 **Bernstein** 条件成立，如果

$$|\mathbb{E}[(X - \mu)^k]| \leq \frac{1}{2} k! \sigma^2 b^{k-2} \quad k = 2, 3, 4, \dots \quad (2.10)$$

Bernstein 条件的一个充分条件是 X 有界。 (?)

满足 Bernstein 条件的随机变量是次指数的。利用指数函数的幂级数展开可以得到，

$$\mathbb{E}[e^{\lambda(X-\mu)}] \leq \exp\left(\frac{\lambda^2 \sigma^2 / 2}{1 - b|\lambda|}\right) \leq \exp\left(\frac{\lambda^2 (\sqrt{2}\sigma)^2}{2}\right), \quad \forall |\lambda| < \frac{1}{2b}. \quad (2.11)$$

即 X 是参数为 $(\sqrt{2}\sigma, 2b)$ 的次指数随机变量。

由 Bernstein 条件，可以得到常数项更紧的尾部概率界。

命题 2.4 (Bernstein 型界)

对任意满足 Bernstein 条件 (2.10) 的随机变量 X , 有

$$\mathbb{E}[e^{\lambda(X-\mu)}] \leq \exp\left(\frac{\lambda^2 \sigma^2 / 2}{1 - b|\lambda|}\right), \quad \forall |\lambda| < \frac{1}{b}. \quad (2.12)$$

以及集中不等式

$$\mathbb{P}[|X - \mu| \geq t] \leq 2 \exp\left(-\frac{t^2}{2(\sigma^2 + bt)}\right), \quad \forall t \geq 0. \quad (2.13)$$

证明 运用矩母函数的界, 在 Chernoff 界中取 $\lambda = \frac{t}{bt + \sigma^2} \in \left[0, \frac{1}{b}\right)$ 即证。□

性质 由定义易得, 和次高斯性一样, 独立次指数随机变量的和同样保持次指数性。

设 $\{X_k\}_{k=1}^n$ 是独立的次指数随机变量, 对应的均值为 μ_k , 参数为 (ν_k, α_k) , 则 $\sum_{k=1}^n (X_k - \mu_k)$

是参数为 $(\sqrt{\sum_{k=1}^n \nu_k^2}, \max_{1 \leq k \leq n} \alpha_k)$ 的次指数随机变量。

对次指数随机变量, 同样有很多等价的描述方式。

定理 2.5 (次指数随机变量的等价描述)

对一个均值为 0 的随机变量 X , 下面的几个定义等价:

(I) 存在非负参数 (ν, α) 使得

$$\mathbb{E}[e^{\lambda X}] \leq \exp\left(\frac{\nu^2 \lambda^2}{2}\right), \quad \forall |\lambda| < \frac{1}{\alpha}.$$

(II) 存在一个正常数 $c_0 > 0$, 使得对任意 $|\lambda| \leq c_0$, 都有 $\mathbb{E}[e^{\lambda X}] < \infty$ 。

(III) 存在常数 $c_1, c_2 > 0$, 使得

$$\mathbb{P}[|X| \geq t] \leq c_1 e^{-c_2 t}, \quad \forall t > 0.$$

(IV) 量 $\gamma := \sup_{k \geq 2} \left[\frac{\mathbb{E}[X^k]}{k!} \right]^{\frac{1}{k}} < \infty$ 。

2.1.4 一些单边结果**命题 2.6 (单侧 Bernstein 不等式)**

如果 $X \leq b$, a.s., 那么

$$\mathbb{E}[e^{\lambda(X - \mathbb{E}[X])}] \leq \exp\left(\frac{\frac{\lambda^2}{2} \mathbb{E}[X^2]}{1 - \frac{b\lambda}{3}}\right), \quad \forall \lambda \in [0, 3/b). \quad (2.14)$$

相对应的, 给定 n 个满足条件 $X_i \leq b$, a.s. 的独立随机变量, 有

$$\mathbb{P}\left[\sum_{i=1}^n (X_i - \mathbb{E}[X_i]) \geq n\delta\right] \leq \exp\left(-\frac{n\delta^2}{2\left(\frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i^2] + \frac{b\delta}{3}\right)}\right). \quad (2.15)$$

如果一个随机变量 X 有下界, 考虑 $-X$ 可以得到它的下尾部不等式。特别地, 对独立非

负随机变量 $Y_i \geq 0$, 有

$$\mathbb{P} \left[\sum_{i=1}^n (Y_i - \mathbb{E}[Y_i]) \leq -n\delta \right] \leq \exp \left(-\frac{n\delta^2}{\frac{2}{n} \sum_{i=1}^n \mathbb{E}[Y_i^2]} \right). \quad (2.16)$$

证明 对 $e^{\lambda X}$ 泰勒展开并取期望

$$\mathbb{E}[e^{\lambda X}] = 1 + \lambda \mathbb{E}[X] + \frac{1}{2} \lambda^2 \mathbb{E}[X^2 h(\lambda X)],$$

其中

$$h(u) := 2 \frac{e^u - u - 1}{u^2} = 2 \sum_{k=2}^{\infty} \frac{u^{k-2}}{k!}.$$

由 $h(u)$ 的单调性可得

$$h(\lambda x) \leq h(\lambda b) \leq \sum_{k=2}^{\infty} \left(\frac{\lambda b}{3} \right)^{k-2} = \frac{1}{1 - \frac{\lambda b}{3}}, \quad \lambda \in [0, 3/b).$$

故

$$\begin{aligned} \mathbb{E}[e^{\lambda(X - \mathbb{E}[X])}] &\leq e^{-\lambda \mathbb{E}[X]} \left(1 + \lambda \mathbb{E}[X] + \frac{1}{2} \lambda^2 \mathbb{E}[X^2] h(\lambda b) \right) \\ &\leq \exp \left\{ \frac{\lambda^2 \mathbb{E}[X^2]}{2} h(\lambda b) \right\} \\ &\leq \exp \left\{ \frac{\frac{\lambda^2}{2} \mathbb{E}[X^2]}{1 - \frac{b\lambda}{3}} \right\}, \quad \forall \lambda \in [0, 3/b). \end{aligned}$$

由 Chernoff 界得

$$\mathbb{P} \left[\sum_{i=1}^n (X_i - \mathbb{E}[X_i]) \geq n\delta \right] \leq \exp \left\{ -\lambda n\delta + \frac{\frac{\lambda^2}{2} \sum_{i=1}^n \mathbb{E}[X_i^2]}{1 - \frac{b\lambda}{3}} \right\}, \quad \forall \lambda \in [0, 3/b).$$

取

$$\lambda = \frac{n\delta}{\sum_{i=1}^n \mathbb{E}[X_i^2] + \frac{n\delta b}{3}} \in [0, 3/b)$$

即证。 □

2.2 基于鞅的方法

推导随机变量的更一般函数的不等式界, 解决这类问题的一种经典技巧是鞅的分解。

2.2.1 背景

令 $\{X_k\}_{k=1}^n$ 为一列独立随机变量, 对于函数 $f: \mathbb{R}^d \rightarrow \mathbb{R}^d$, $f(X) = f(X_1, \dots, X_n)$, 假设我们的目标是研究函数 f 与其均值之间偏差的概率界。考虑随机变量序列 $Y_0 = \mathbb{E}[f(X)]$, $Y_n = f(X)$, 以及

$$Y_k = \mathbb{E}[f(X) \mid X_1, \dots, X_k], \quad k = 1, \dots, n-1. \quad (2.17)$$

假定上述所有条件期望均存在，基于下面的伸缩分解：

$$f(X) - \mathbb{E}[f(X)] = Y_n - Y_0 = \sum_{k=1}^n (Y_k - Y_{k-1}) =: \sum_{k=1}^n D_k.$$

序列 $\{Y_k\}_{k=1}^n$ 是一个鞅序列，称为 **Doob 鞅**，而 $\{D_k\}_{k=1}^n$ 则是一个鞅差序列。

定义 2.3 (鞅)

令 $\{\mathcal{F}_k\}_{k=1}^\infty$ 为一列非降的 σ 域，即对 $\forall k \geq 1$ 有 $\mathcal{F}_k \subset \mathcal{F}_{k+1}$ ，这样的序列称为域流。给定一个适应于域流 $\{\mathcal{F}_k\}_{k=1}^\infty$ 的随机变量序列 $\{Y_k\}_{k=1}^\infty$ ，如果对 $\forall k \geq 1$ ，有

$$\mathbb{E}[|Y_k|] < \infty \quad \text{和} \quad \mathbb{E}[Y_{k+1} | \mathcal{F}_k] = Y_k, \quad (2.18)$$

那么称 $\{(Y_k, \mathcal{F}_k)\}_{k=1}^\infty$ 是一个鞅。

例 2.4 (Doob 构造)

假设函数 f 绝对可积，即 $\mathbb{E}[|f(X)|] < \infty$ ，那么前面讨论的 Doob 构造确实是一个鞅。

记 $X_1^k = (X_1, X_2, \dots, X_k)$ ，由 Jensen 不等式及条件期望的性质，

$$\begin{aligned} \mathbb{E}[|Y_k|] &= \mathbb{E}[|\mathbb{E}[f(X) | X_1^k]|] \leq \mathbb{E}[|f(X)|] < \infty, \\ \mathbb{E}[Y_{k+1} | X_1^k] &= \mathbb{E}[\mathbb{E}[f(X) | X_1^{k+1}] | X_1^k] = \mathbb{E}[f(X) | X_1^k] = Y_k. \end{aligned}$$

一个密切相关的概念是鞅差序列，表示一个适应序列 $\{(D_k, \mathcal{F}_k)\}_{k=1}^\infty$ 对 $\forall k \geq 1$ ，满足

$$\mathbb{E}[|D_k|] < \infty \quad \text{和} \quad \mathbb{E}[D_{k+1} | \mathcal{F}_k] = 0. \quad (2.19)$$

2.2.2 鞅差序列的集中度界

首先通过在鞅差序列上加上次指数条件，得到一个一般的鞅差序列的 Bernstein 型界。

定理 2.7 (鞅差序列的 Bernstein 界)

令 $\{(D_k, \mathcal{F}_k)\}_{k=1}^\infty$ 为一个鞅差序列，并假设对任意的 $|\lambda| < 1/\alpha_k$ ，有 $\mathbb{E}[e^{\lambda D_k} | \mathcal{F}_{k-1}] \leq e^{\lambda^2 \nu_k^2 / 2}$, a.s.，那么下面的结论成立：

- (a) $\sum_{k=1}^n D_k$ 是参数为 $\left(\sqrt{\sum_{k=1}^n \nu_k^2}, \alpha_*\right)$ 的次指数随机变量，其中 $\alpha_* = \max_{1 \leq k \leq n} \alpha_k$ 。
 (b) 有集中不等式

$$\mathbb{P}\left[\left|\sum_{k=1}^n D_k\right| \geq t\right] \leq \begin{cases} 2 \exp\left(-\frac{t^2}{2 \sum_{k=1}^n \nu_k^2}\right), & 0 \leq t \leq \frac{\sum_{k=1}^n \nu_k^2}{\alpha_*}, \\ 2 \exp\left(-\frac{t}{2\alpha_*}\right), & t > \frac{\sum_{k=1}^n \nu_k^2}{\alpha_*}. \end{cases} \quad (2.20)$$

证明 在 \mathcal{F}_{k-1} 下求条件期望

$$\mathbb{E}\left[e^{\lambda \sum_{k=1}^n D_k}\right] = \mathbb{E}\left[e^{\lambda \sum_{k=1}^{n-1} D_k} \mathbb{E}[e^{\lambda D_n} | \mathcal{F}_{n-1}]\right] \leq \mathbb{E}\left[e^{\lambda \sum_{k=1}^{n-1} D_k}\right] e^{\lambda^2 \nu_n^2 / 2}, \quad (2.21)$$

可以验证次指数性，再由命题 2.3 即得集中不等式。□

推论 2.8 (Azuma-Hoeffding)

令 $\{(D_k, \mathcal{F}_k)\}_{k=1}^\infty$ 为一个鞅差序列, 满足对所有的 $k = 1, \dots, n$, 存在常数 $\{(a_k, b_k)\}_{k=1}^n$, 使得 $D_k \in [a_k, b_k]$, a.s., 那么, 对 $\forall t \geq 0$,

$$\mathbb{P} \left[\left| \sum_{k=1}^n D_k \right| \geq t \right] \leq 2 \exp \left(- \frac{2t^2}{\sum_{k=1}^n (b_k - a_k)^2} \right). \quad (2.22)$$

推论 2.8 的一个重要应用是研究满足有界差性质的函数。给定向量 $\mathbf{x}, \mathbf{x}' \in \mathbb{R}^n$ 和一个指标 $k \in \{1, 2, \dots, n\}$, 定义新的向量 $\mathbf{x}^{\setminus k} \in \mathbb{R}^n$

$$x_j^{\setminus k} := \begin{cases} x_j & \text{如果 } j \neq k, \\ x'_k & \text{如果 } j = k. \end{cases} \quad (2.23)$$

我们称 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 满足参数为 (L_1, \dots, L_n) 的有界差不等式, 如果对 $\forall k = 1, 2, \dots, n$, 有

$$|f(\mathbf{x}) - f(\mathbf{x}^{\setminus k})| \leq L_k, \quad \forall \mathbf{x}, \mathbf{x}' \in \mathbb{R}^n. \quad (2.24)$$

推论 2.9 (有界差不等式)

假设 f 满足参数为 (L_1, \dots, L_n) 的有界差性质 (2.24), 且随机向量 $\mathbf{X} = (X_1, \dots, X_n)$ 各分量独立, 则

$$\mathbb{P}[|f(\mathbf{X}) - \mathbb{E}[f(\mathbf{X})]| \geq t] \leq 2 \exp \left(- \frac{2t^2}{\sum_{k=1}^n L_k^2} \right), \quad \forall t \geq 0. \quad (2.25)$$

证明 考虑 Doob 分解对应的鞅差序列

$$D_k = \mathbb{E}[f(\mathbf{X}) \mid X_1, \dots, X_k] - \mathbb{E}[f(\mathbf{X}) \mid X_1, \dots, X_{k-1}].$$

记

$$A_k := \inf_x \mathbb{E}[f(\mathbf{X}) \mid X_1, \dots, X_{k-1}, x] - \mathbb{E}[f(\mathbf{X}) \mid X_1, \dots, X_{k-1}],$$

$$B_k := \sup_x \mathbb{E}[f(\mathbf{X}) \mid X_1, \dots, X_{k-1}, x] - \mathbb{E}[f(\mathbf{X}) \mid X_1, \dots, X_{k-1}].$$

证明 $A_k \leq D_k \leq B_k$, a.s. 且 $B_k - A_k \leq L_k$, 再由推论 2.8 Azuma-Hoeffding 不等式即证。□

例 2.5 (有界差经典 Hoeffding 界)

考虑函数 $f(x_1, \dots, x_n) = \sum_{i=1}^n (x_i - \mu_i)$, 其中 $\mu_i = \mathbb{E}[X_i]$ 。对 $\forall k \in \{1, \dots, n\}$, 有 $|f(\mathbf{x}) - f(\mathbf{x}^{\setminus k})| = |(x_k - \mu_k) - (x'_k - \mu_k)| = |x_k - x'_k| \leq b - a$, 从而可以得到独立随机变量的经典 Hoeffding 不等式界

$$\mathbb{P} \left[\left| \sum_{i=1}^n (X_i - \mu_i) \right| \geq t \right] \leq 2 \exp \left(- \frac{2t^2}{n(b-a)^2} \right).$$

例 2.6 (U 统计量)

令 $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ 为一个关于两个自变量对称的函数, 给定一系列独立同分布的随机变量 $X_k (k \geq 1)$, 统计量

$$U := \frac{1}{\binom{n}{2}} \sum_{j < k} g(X_j, X_k) \quad (2.26)$$

被称为 U 统计量。如果 g 有界 (即 $\|g\|_\infty \leq b$), 那么就有

$$\mathbb{P}[|U - \mathbb{E}[U]| \geq t] \leq 2 \exp\left(-\frac{nt^2}{8b^2}\right).$$

这个尾部不等式保证了 U 是 $\mathbb{E}[U]$ 的相合估计。

证明 记 $U = f(\mathbf{x}) = f(x_1, \dots, x_n)$, 对任意给定的 k , 有

$$|f(\mathbf{x}) - f(\mathbf{x}^{\setminus k})| \leq \frac{1}{\binom{n}{2}} \sum_{j \neq k} |g(x_j, x_k) - g(x_j, x'_k)| \leq \frac{(n-1)(2b)}{\binom{n}{2}} = \frac{4b}{n},$$

即 f 满足参数为 $L_k = \frac{4b}{n}$ 的有界差性质, 由推论 2.9 有界差不等式即证。□

例 2.7 (Rademacher 复杂度)

令 $\{\varepsilon_k\}_{k=1}^n$ 为一个独立同分布的 Rademacher 随机变量序列。给定一个向量集合 $\mathcal{A} \subset \mathbb{R}^n$, 定义随机变量

$$Z(\mathcal{A}) := \sup_{\mathbf{a} \in \mathcal{A}} \left[\sum_{k=1}^n a_k \varepsilon_k \right] = \sup_{\mathbf{a} \in \mathcal{A}} [\langle \mathbf{a}, \boldsymbol{\varepsilon} \rangle]. \quad (2.27)$$

这个随机变量 Z 从某种意义上度量了 \mathcal{A} 的大小, 而其期望 $\mathcal{R}(\mathcal{A}) := \mathbb{E}[Z(\mathcal{A})]$ 称为集合 \mathcal{A} 的 **Rademacher** 复杂度。

由有界差不等式可以得到, $Z(\mathcal{A})$ 是次高斯的, 其参数至多为 $\sqrt{\sum_{k=1}^n \sup_{\mathbf{a} \in \mathcal{A}} a_k^2}$ 。

证明 给定 \mathcal{A} , 把 $Z(\mathcal{A})$ 看成是 $\boldsymbol{\varepsilon}$ 的函数 $f(\boldsymbol{\varepsilon}) = f(\varepsilon_1, \dots, \varepsilon_n)$, 由于

$$\langle \mathbf{a}, \boldsymbol{\varepsilon} \rangle - f(\boldsymbol{\varepsilon}^{\setminus k}) \leq \langle \mathbf{a}, \boldsymbol{\varepsilon} - \boldsymbol{\varepsilon}^{\setminus k} \rangle = a_k(\varepsilon_k - \varepsilon'_k) \leq 2|a_k|,$$

两边同时在 \mathcal{A} 上取最大值, 则得到不等式

$$f(\boldsymbol{\varepsilon}) - f(\boldsymbol{\varepsilon}^{\setminus k}) \leq 2 \sup_{\mathbf{a} \in \mathcal{A}} |a_k|.$$

从而 f 满足有界差性质, 由推论 2.9 得

$$\mathbb{P}[|Z(\mathcal{A}) - \mathbb{E}[Z(\mathcal{A})]| \geq t] \leq 2 \exp\left(-\frac{t^2}{2 \sum_{k=1}^n \sup_{\mathbf{a} \in \mathcal{A}} a_k^2}\right)$$

□

2.3 高斯随机变量的 Lipschitz 函数

对于经典的高斯随机变量的 Lipschitz 函数的集中不等式，有一个非常有用的性质：集中度与维数无关。

称一个函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在欧几里得范数 $\|\cdot\|_2$ 意义下是 L -Lipschitz 的，如果

$$|f(\mathbf{x}) - f(\mathbf{y})| \leq L \|\mathbf{x} - \mathbf{y}\|_2, \quad \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n. \quad (2.28)$$

定理 2.10

令 (X_1, \dots, X_n) 是由独立同分布的标准正态随机变量生成的向量，函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是在欧几里得范数意义下的 L -Lipschitz 函数。那么随机变量 $f(\mathbf{X}) - \mathbb{E}[f(\mathbf{X})]$ 是参数至多为 L 的次高斯随机变量，且

$$\mathbb{P}[|f(\mathbf{X}) - \mathbb{E}[f(\mathbf{X})]| \geq t] \leq 2 \exp\left(-\frac{t^2}{2L^2}\right), \quad \forall t \geq 0. \quad (2.29)$$

注 这个定理保证了对一个标准正态随机向量的任意 L -Lipschitz 函数，无论其维数如何，都是次高斯的，且参数最大为 L ，其集中度的表现与一元的方差为 L^2 的正态随机变量相似。

证明 利用下面的引理可以证明一个常数弱化后的版本。

引理 2.11

若函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 可微，则对任意凸函数 $\phi: \mathbb{R} \rightarrow \mathbb{R}$ ，有

$$\mathbb{E}[\phi(f(X) - \mathbb{E}[f(X)])] \leq \mathbb{E}\left[\phi\left(\frac{\pi}{2} \langle \nabla f(X), Y \rangle\right)\right], \quad (2.30)$$

其中 $X, Y \sim \mathcal{N}(0, \mathbf{I}_n)$ 是独立的标准多元正态向量。

由此可以推出 $f(X) - \mathbb{E}[f(X)]$ 是参数为 $\frac{\pi L}{2}$ 的次高斯随机变量，取 Hoeffding 界即证。□

注 在上述定理的证明过程中，标准正态分布的各种性质起到了关键作用。但事实上，类似的结果对其他非正态分布同样成立，如球面上的均匀分布和任意严格对数凹的分布。但是如果没有关于函数 f 的结构性质，上述不依赖于维数集中度的结论对任意的次高斯分布未必成立。

例 2.8 (χ^2 集中度)

对任意给定的独立同分布的标准正态随机变量序列 $\{Z_k\}_{k=1}^n$ ，随机变量 $Y := \sum_{k=1}^n Z_k^2$ 服从自由度为 n 的 χ^2 分布。注意 Z_k^2 是次指数的且相互独立，可以得到 Y 的尾部不等式。事实上，基于正态分布的 Lipschitz 函数的集中不等式，可以给出另一种推导方式。

令 $V = \sqrt{\frac{Y}{n}}$ ，由于欧几里得范数是 1-Lipschitz 函数，对其应用定理 2.10。

例 2.9 (次序统计量)

给定随机向量 (X_1, \dots, X_n) 和 (Y_1, \dots, Y_n) ，有 $|X_{(k)} - Y_{(k)}| \leq \|\mathbf{X} - \mathbf{Y}\|_2$ ，故每个次序

统计量都是 1-Lipschitz 函数。因此，当 \mathbf{X} 是一个正态随机向量时，由定理 2.10 有

$$\mathbb{P}[|X_{(k)} - \mathbb{E}[X_{(k)}]| \geq \delta] \leq 2e^{-\frac{\delta^2}{2}}, \quad \forall \delta \geq 0.$$

例 2.10 (高斯复杂度)

令 $\{W_k\}_{k=1}^n$ 为独立同分布的标准正态随机变量序列。给定一个向量集合 $\mathcal{A} \subset \mathbb{R}^n$ ，定义随机变量

$$Z(\mathcal{A}) := \sup_{\mathbf{a} \in \mathcal{A}} \left[\sum_{k=1}^n a_k W_k \right] = \sup_{\mathbf{a} \in \mathcal{A}} [\langle \mathbf{a}, \mathbf{W} \rangle]. \quad (2.31)$$

和 Rademacher 复杂度一样，随机变量 Z 也是刻画 \mathcal{A} 大小的一种方式。

把 Z 看成 \mathbf{W} 的函数 $f(\mathbf{W}) = f(W_1, \dots, W_n)$ ，则 f 是参数为 $\sup_{\mathbf{a} \in \mathcal{A}} \|\mathbf{a}\|_2$ 的 Lipschitz 函数。

证明 对 $\forall \mathbf{w}, \mathbf{w}' \in \mathbb{R}^n$ ，令 $\mathbf{a}^* \in \mathcal{A}$ 为使 $f(\mathbf{w})$ 达到最大值的向量，则

$$f(\mathbf{w}) - f(\mathbf{w}') \leq \langle \mathbf{a}^*, \mathbf{w} - \mathbf{w}' \rangle \leq \|\mathbf{a}^*\|_2 \|\mathbf{w} - \mathbf{w}'\|_2 \leq D(\mathcal{A}) \|\mathbf{w} - \mathbf{w}'\|_2,$$

其中 $D(\mathcal{A}) = \sup_{\mathbf{a} \in \mathcal{A}} \|\mathbf{a}\|_2$ ，故 f 是参数为 $D(\mathcal{A})$ 的 Lipschitz 函数，从而有

$$\mathbb{P}[|Z - \mathbb{E}[Z]| \geq \delta] \leq 2 \exp\left(-\frac{\delta^2}{2D^2(\mathcal{A})}\right). \quad (2.32)$$

□

设 $\mathbf{Q} \in \mathbb{R}^{n \times n}$ 为一个对称矩阵，则矩阵 \mathbf{Q} 的 ℓ_2 算子范数为

$$\|\mathbf{Q}\|_2 := \sup_{\|u\|_2=1} \|\mathbf{Q}u\|_2. \quad (2.33)$$

矩阵 \mathbf{Q} 的 Frobenius 范数为

$$\|\mathbf{Q}\|_F := \sqrt{\sum_{i=1}^n \sum_{j=1}^n Q_{ij}^2}. \quad (2.34)$$

2.4 附录 A：次高斯随机变量的等价性

2.5 附录 B：次指数随机变量的等价性

第3章 测度集中度

3.1 基于熵技巧的集中度

3.1.1 熵及其相关性质

给定一个凸函数 $\phi: \mathbb{R} \rightarrow \mathbb{R}$, 只要 $\mathbb{E}[X]$ 和 $\mathbb{E}[\phi(X)]$ 都存在, 就可以定义概率空间上的一个泛函

$$\mathbb{H}_\phi(X) := \mathbb{E}[\phi(X)] - \phi(\mathbb{E}[X]), \quad (3.1)$$

其中 $X \sim \mathbb{P}$, 称为随机变量 X 的 ϕ 熵。由 ϕ 的凸性可知 $\mathbb{H}_\phi(X)$ 总是非负的, 它是一个度量随机性变化大小的量。

实际上, 有一些常见的度量随机性变化大小的量其实是 ϕ 熵的一种特殊形式:

- 取 $\phi(u) = u^2$, $\mathbb{H}_\phi(X) = \text{Var}(X)$, 这时的熵对应的是随机变量的方差;
- 取 $\phi(u) = -\log u$, $\mathbb{H}_\phi(X) = \log \mathbb{E}[e^{\lambda(X - \mathbb{E}[X])}]$, 这时的熵对应的是中心化的矩母函数。

在本章中, 考虑的 $\phi: [0, +\infty) \rightarrow \mathbb{R}$ 定义为

$$\phi(u) := u \log u, \quad \forall u > 0, \quad \text{以及} \quad \phi(0) := 0. \quad (3.2)$$

此时, 对任意非负随机变量 $Z \geq 0$, 定义 ϕ 熵为

$$\mathbb{H}(Z) = \mathbb{E}[Z \log Z] - \mathbb{E}[Z] \log \mathbb{E}[Z]. \quad (3.3)$$

对于随机变量 $Z := e^{\lambda X}$, 熵可以通过矩母函数 $\varphi_X(\lambda) = \mathbb{E}[e^{\lambda X}]$ 及其一阶导数表示为

$$\mathbb{H}(e^{\lambda X}) = \lambda \varphi'_X(\lambda) - \varphi_X(\lambda) \log \varphi_X(\lambda). \quad (3.4)$$

例 3.1 (正态随机变量的熵)

对于一元正态随机变量 $X \sim \mathcal{N}(0, \sigma^2)$, 有 $\varphi_X(\lambda) = e^{\lambda^2 \sigma^2 / 2}$, $\varphi'_X(\lambda) = \lambda \sigma^2 \varphi_X(\lambda)$, 因此

$$\mathbb{H}(e^{\lambda X}) = \lambda^2 \sigma^2 \varphi_X(\lambda) - \frac{1}{2} \lambda^2 \sigma^2 \varphi_X(\lambda) = \frac{1}{2} \lambda^2 \sigma^2 \varphi_X(\lambda) \quad (3.5)$$

3.1.2 Herbst 方法及其延伸

直观上来说, 熵是一个度量随机变量波动性的量, 因此熵的控制可以转化为尾部概率界的控制。考虑一类特定的随机变量, 假设存在常数 $\sigma > 0$ 使得 $e^{\lambda X}$ 的熵满足上界

$$\mathbb{H}(e^{\lambda X}) \leq \frac{1}{2} \sigma^2 \lambda^2 \varphi_X(\lambda). \quad (3.6)$$

注 任意正态随机变量 $X \sim \mathcal{N}(0, \sigma^2)$ 对 $\forall \lambda \in \mathbb{R}$ 满足上述条件且取等号, 任意有界随机变量也满足上述条件。

命题 3.1 (Herbst 方法)

假设熵 $\mathbb{H}(e^{\lambda X})$ 对 $\forall \lambda \in I$ 满足不等式 (3.6), 这里 I 可以是区间 $[0, +\infty)$ 或 \mathbb{R} , 则 X 满足

$$\log \mathbb{E}[e^{\lambda(X - \mathbb{E}[X])}] \leq \frac{1}{2} \lambda^2 \sigma^2, \quad \forall \lambda \in I. \quad (3.7)$$

注 当 $I = \mathbb{R}$ 时, 等价于中心化后的随机变量 $X - \mathbb{E}[X]$ 是参数为 σ 的次高斯随机变量。当 $I = [0, +\infty)$ 时, 对应的是次高斯变量的单侧尾部概率界。

证明 由熵的矩母函数表达式, 条件等价于矩母函数 $\varphi = \varphi_X$ 满足

$$\lambda \varphi'(\lambda) - \varphi(\lambda) \log \varphi(\lambda) \leq \frac{1}{2} \sigma^2 \lambda^2 \varphi(\lambda), \quad \forall \lambda \geq 0.$$

定义函数 $G(\lambda) = \frac{1}{\lambda} \log \varphi(\lambda)$, $\varphi(0) = \mathbb{E}[X]$, 则上式等价于 $G'(\lambda) \leq \frac{1}{2} \sigma^2$, 进而有

$$G(\lambda) - \mathbb{E}[X] \leq \frac{1}{2} \lambda \sigma^2,$$

化简即证。 □

命题 3.2 (Bernstein 熵的界)

假设存在正常数 b 和 σ 使得熵 $\mathbb{H}(e^{\lambda X})$ 满足

$$\mathbb{H}(e^{\lambda X}) \leq \lambda^2 \{b \varphi'_x(\lambda) + \varphi_x(\lambda)(\sigma^2 - b \mathbb{E}[X])\}, \quad \forall \lambda \in [0, 1/b]. \quad (3.8)$$

则 X 满足界

$$\log \mathbb{E}[e^{\lambda(X - \mathbb{E}[X])}] \leq \frac{\sigma^2 \lambda^2}{1 - b\lambda}, \quad \forall \lambda \in [0, 1/b]. \quad (3.9)$$

证明 由重尺度化和中心化技巧, 不失一般性, 不妨设 $\mathbb{E}[X] = 0$, $b = 1$, 类似命题 3.1 即证。□

3.1.3 可分凸函数和熵方法

如果对 $\forall k \in \{1, \dots, n\}$, 单变量函数 $y_k \mapsto f(x_1, \dots, x_{k-1}, y_k, x_{k+1}, \dots, x_n)$ 对任意给定的向量 $(x_1, \dots, x_{k-1}, x_{k+1}, \dots, x_n) \in \mathbb{R}^{n-1}$ 是凸的, 则称函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是**可分凸函数**。

定理 3.3

令 $\{X_i\}_{i=1}^n$ 是区间 $[a, b]$ 上的独立随机变量, $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是可分凸且关于欧几里得范数是 L -Lipschitz 的, 那么对 $\forall \delta > 0$, 有

$$\mathbb{P}[f(X) \geq \mathbb{E}[f(X)] + \delta] \leq \exp\left(-\frac{\delta^2}{4L^2(b-a)^2}\right). \quad (3.10)$$

定理 3.3 可以用来获得一系列重要问题的最优界 (order-optimal bound)。

例 3.2 (Rademacher 复杂度的更优界)

给定一个有界子集 $\mathcal{A} \subset \mathbb{R}^n$, 考虑随机变量 $Z = \sup_{a \in \mathcal{A}} \sum_{k=1}^n a_k \varepsilon_k$, 其中 $\varepsilon_k \in \{-1, +1\}$ 为独立同分布的 Rademacher 随机变量, 求 $Z - \mathbb{E}[Z]$ 的尾部概率界。

解 易验证 $Z = f(\epsilon) = f(\epsilon_1, \dots, \epsilon_n)$ 是完全凸的, 因此也是可分凸的。对 $\forall \mathbf{a} \in \mathcal{A}$, 有

$$\langle \mathbf{a}, \epsilon \rangle - f(\epsilon') = \langle \mathbf{a}, \epsilon \rangle - \sup_{\mathbf{a}' \in \mathcal{A}} \langle \mathbf{a}', \epsilon' \rangle \leq \langle \mathbf{a}, \epsilon - \epsilon' \rangle \leq \|\mathbf{a}\|_2 \|\epsilon - \epsilon'\|_2.$$

从而可以推出 Z 是 Lipschitz 的, 参数为 $\mathcal{W}(\mathcal{A}) := \sup_{\mathbf{a} \in \mathcal{A}} \|\mathbf{a}\|_2$ 。由定理 3.3, 有

$$\mathbb{P}[Z \geq \mathbb{E}[Z] + t] \leq \exp\left(-\frac{t^2}{16\mathcal{W}^2(\mathcal{A})}\right). \quad (3.11)$$

注意这里的参数 $\mathcal{W}^2(\mathcal{A})$ 可能比例 2.7 中得到的 $\sum_{k=1}^n \sup_{\mathbf{a} \in \mathcal{A}} a_k^2$ 小很多。 \square

3.1.4 张量化和可分凸函数

为了证明定理 3.3, 先引入两个引理, 这两个引理本身也都很重要。

引理 3.4 (单变量函数基于熵的界)

设 $X, Y \sim \mathbb{P}$ 是一对独立同分布的随机变量, 则对任意函数 $g: \mathbb{R} \rightarrow \mathbb{R}$, 有

$$\mathbb{H}(e^{\lambda g(X)}) \leq \lambda^2 \mathbb{E}[(g(X) - g(Y))^2 e^{\lambda g(X)} \mathbb{I}[g(X) \geq g(Y)]] , \quad \forall \lambda > 0. \quad (3.12)$$

另外, 如果 X 以 $[a, b]$ 为支撑集, g 是凸且 Lipschitz 的, 则

$$\mathbb{H}(e^{\lambda g(X)}) \leq \lambda^2 (b-a)^2 \mathbb{E}[(g'(X))^2 e^{\lambda g(X)}], \quad \forall \lambda > 0, \quad (3.13)$$

其中 g' 为 g 的导数。

注 由 **Rademacher** 定理, 任意一个凸的 Lipschitz 函数几乎处处有导数。进一步, 如果 g 是参数为 L 的 Lipschitz 函数, 则有 $\|g'\|_\infty \leq L$, 于是可以进一步推出

$$\mathbb{H}(e^{\lambda g(X)}) \leq \lambda^2 L^2 (b-a)^2 \mathbb{E}[e^{\lambda g(X)}], \quad \forall \lambda > 0.$$

应用命题 3.1, 可以推出定理 3.3 的单变量版本。

为了将一元的结果推广至多元的情形, 熵的张量化性质会起到关键作用。考虑一个函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 下标 $k \in \{1, \dots, n\}$ 和向量 $\mathbf{x}_{\setminus k} = (x_i, i \neq k) \in \mathbb{R}^{n-1}$, 定义坐标 k 的条件熵为

$$\mathbb{H}(e^{\lambda f_k(X_k)} \mid \mathbf{x}_{\setminus k}) := \mathbb{H}(e^{\lambda f(x_1, \dots, x_{k-1}, X_k, x_{k+1}, \dots, x_n)}), \quad (3.14)$$

其中 $f_k: \mathbb{R} \rightarrow \mathbb{R}$ 是坐标函数 $x_k \mapsto f(x_1, \dots, x_k, \dots, x_n)$ 。

定理 3.5 (熵的张量化)

令 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $\{X_k\}_{k=1}^n$ 为独立随机变量, 则

$$\mathbb{H}(e^{\lambda f(X_1, \dots, X_n)}) \leq \mathbb{E} \left[\sum_{k=1}^n \mathbb{H}(e^{\lambda f_k(X_k)} \mid X^{\setminus k}) \right], \quad \forall \lambda > 0. \quad (3.15)$$

注 这个结果说明, 多变量熵可以被适当定义的单变量条件熵之和控制住上界。

证明 [定理 3.3 的证明] 由引理 3.4, 对 $\forall \lambda > 0$, 有

$$\begin{aligned} \mathbb{H}(e^{\lambda f_k(X_k)} | x_{\setminus k}) &\leq \lambda^2 (b-a)^2 \mathbb{E}_{X_k} \left[(f'_k(X_k))^2 e^{\lambda f_k(X_k)} | x_{\setminus k} \right] \\ &= \lambda^2 (b-a)^2 \mathbb{E}_{X_k} \left[\left(\frac{\partial f(x_1, \dots, X_k, \dots, x_n)}{\partial x_k} \right)^2 e^{\lambda f(x_1, \dots, X_k, \dots, x_n)} \right], \end{aligned}$$

结合引理 3.5,

$$\mathbb{H}(e^{\lambda f(X)}) \leq \lambda^2 (b-a)^2 \mathbb{E} \left[\sum_{k=1}^n \left(\frac{\partial f(X)}{\partial x_k} \right)^2 e^{\lambda f(X)} \right] \leq \lambda^2 (b-a)^2 L^2 \mathbb{E} [e^{\lambda f(X)}].$$

再由命题 3.1 即证。 \square

3.2 集中度的几何观点

度量测度空间指的是一个度量空间 (\mathcal{X}, ρ) 在其 Borel 集上被赋予了一个概率测度 \mathbb{P} 。经典的度量空间如 $\mathcal{X} = \mathbb{R}^n$ 上赋予了欧几里得度量 $\rho(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2$ 和离散方体 $\mathcal{X} = \{0, 1\}^n$ 上赋予了 Hamming 度量 $\rho(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^n \mathbb{I}[x_i \neq y_i]$ 。

3.2.1 集中度函数

与度量测度空间相关的是集中度函数, 它是借助集合的 ϵ 扩张用几何方式定义的, 详细刻画了 ϵ 扩张趋向于 1 的速度有多快。

给定一个集合 $A \subseteq \mathcal{X}$ 和一个点 $x \in \mathcal{X}$, 定义点 x 到集合 A 的距离为

$$\rho(x, A) := \inf_{y \in A} \rho(x, y). \quad (3.16)$$

给定一个参数 $\epsilon > 0$, 定义 A 的 ϵ 扩张为

$$A^\epsilon := \{x \in \mathcal{X} : \rho(x, A) < \epsilon\}. \quad (3.17)$$

定义 3.1 (集中度函数)

度量测度空间 $(\mathbb{P}, \mathcal{X}, \rho)$ 的集中度函数 $\alpha : [0, +\infty) \rightarrow \mathbb{R}_+$ 定义为

$$\alpha_{\mathbb{P}, (\mathcal{X}, \rho)}(\epsilon) := \sup_{A \subseteq \mathcal{X}} \left\{ 1 - \mathbb{P}[A^\epsilon] : \mathbb{P}[A] \geq \frac{1}{2} \right\}, \quad (3.18)$$

其中上确界在所有可测子集 A 上取。有时也把上述记号简记为 $\alpha_{\mathbb{P}}$ 。

我们主要感兴趣的是, 当 ϵ 增加时, 集中度函数趋向于 0 的速度有多快。

例 3.3 (球面的集中度函数)

考虑 n 维欧几里得球面上的均匀分布定义的度量测度空间

$$\mathbb{S}^{n-1} := \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\|_2 = 1\}, \quad (3.19)$$

其上的度量为测地线度量 $\rho(\mathbf{x}, \mathbf{y}) = \arccos \langle \mathbf{x}, \mathbf{y} \rangle$ 。

3.2.2 与 Lipschitz 函数的联系

命题 3.6 (集中度函数的控制与 Lipschitz 函数的控制等价)

给定随机变量 $X \sim \mathbb{P}$ 和集中度函数 $\alpha_{\mathbb{P}}$, 任意一个 (\mathcal{X}, ρ) 上的 1-Lipschitz 函数 f 满足

$$\mathbb{P}[|f(X) - m_f| \geq \epsilon] \leq 2\alpha_{\mathbb{P}}(\epsilon), \quad (3.20)$$

其中 m_f 是 f 的任意中位数。

反之, 假设有一个函数 $\beta: \mathbb{R}_+ \rightarrow \mathbb{R}_+$, 满足对任意一个 (\mathcal{X}, ρ) 上的 1-Lipschitz 函数 f 有

$$\mathbb{P}[f(X) \geq \mathbb{E}[f(X)] + \epsilon] \leq \beta(\epsilon), \quad \forall \epsilon \geq 0, \quad (3.21)$$

那么集中度函数满足界 $\alpha_{\mathbb{P}}(\epsilon) \leq \beta(\epsilon/2)$ 。

3.2.3 从几何到集中度

称函数 $\psi: \mathbb{R}^n \rightarrow \mathbb{R}$ 是**强凸函数**, 如果存在常数 $\gamma > 0$, 对 $\forall \lambda \in [0, 1]$ 和 $\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, 有

$$\lambda\psi(\mathbf{x}) + (1 - \lambda)\psi(\mathbf{y}) - \psi(\lambda\mathbf{x} + (1 - \lambda)\mathbf{y}) \geq \frac{\gamma}{2}\lambda(1 - \lambda)\|\mathbf{x} - \mathbf{y}\|_2^2. \quad (3.22)$$

称一个分布 \mathbb{P} 关于密度 p 是**强对数凹分布**, 如果这个密度可以写成 $p(\mathbf{x}) = \exp(-\psi(\mathbf{x}))$ 的形式, 其中函数 $\psi: \mathbb{R}^n \rightarrow \mathbb{R}$ 是强凸的。例如, n 维标准正态分布是参数 $\gamma = 1$ 的强对数凹分布。

定理 3.7

设 \mathbb{P} 是参数 $\gamma > 0$ 的强对数凹分布, 那么对任意欧几里得范数意义下的 L -Lipschitz 函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 有

$$\mathbb{P}[|f(X) - \mathbb{E}[f(X)]| \geq t] \leq 2 \exp\left(-\frac{\gamma t^2}{4L^2}\right). \quad (3.23)$$

3.3 Wasserstein 距离和传输成本不等式

3.3.1 Wasserstein 距离

给定一个度量空间 (\mathcal{X}, ρ) , 称一个函数 $f: \mathcal{X} \rightarrow \mathbb{R}$ 关于度量 ρ 是 L -Lipschitz 的, 如果

$$|f(x) - f(x')| \leq L\rho(x, x'), \quad \forall x, x' \in \mathcal{X}. \quad (3.24)$$

记 $\|f\|_{\text{Lip}}$ 为满足上述不等式的最小的 L 。

给定 \mathcal{X} 上的两个概率分布 \mathbb{Q}, \mathbb{P} , 称由 ρ 诱导出的 **Wasserstein 度量**为

$$W_{\rho}(\mathbb{Q}, \mathbb{P}) = \sup_{\|f\|_{\text{Lip}} \leq 1} \left[\int f d\mathbb{Q} - \int f d\mathbb{P} \right]. \quad (3.25)$$

对于每一个 ρ 的选取, 这定义了一个概率测度空间上的距离。

例 3.4 (Hamming 度量和全变差距离)

考虑 Hamming 度量 $\rho(x, x') = \mathbb{I}[x \neq x']$, 我们断言, 与此相对应的 Wasserstein 距离等价于全变差距离

$$\|\mathbb{Q} - \mathbb{P}\|_{\text{TV}} := \sup_{A \subseteq \mathcal{X}} |\mathbb{Q}(A) - \mathbb{P}(A)|, \quad (3.26)$$

这里的上确界在所有可测子集 A 上取。

由对偶理论中一个经典的结果, 任意 Wasserstein 距离都有一个基于耦合距离类型的等价定义。称乘积空间 $\mathcal{X} \times \mathcal{X}$ 上的一个分布 \mathbb{M} 为关于 (\mathbb{Q}, \mathbb{P}) 的一个耦合, 如果其第一和第二坐标的边缘分布分别与 \mathbb{Q} 和 \mathbb{P} 相吻合。

事实上, 关于 Wasserstein 距离和耦合, 我们有等价性

$$W_\rho(\mathbb{Q}, \mathbb{P}) = \sup_{\|f\|_{\text{Lip}} \leq 1} \int f(d\mathbb{Q} - d\mathbb{P}) = \inf_{\mathbb{M}} \int_{\mathcal{X} \times \mathcal{X}} \rho(x, x') d\mathbb{M}(x, x') = \inf_{\mathbb{M}} \mathbb{E}_{\mathbb{M}}[\rho(X, X')], \quad (3.27)$$

其中下确界在所有 (\mathbb{Q}, \mathbb{P}) 的耦合 \mathbb{M} 上取。这个基于耦合的 Wasserstein 距离表达式在接下来的证明中非常重要。

“传输成本”的术语来自于对基于耦合的表达式 (3.27) 的另一种理解。考虑 \mathcal{X} 上 \mathbb{P}, \mathbb{Q} 关于 Lebesgue 测度有密度 p, q , 且在乘积空间上的耦合 \mathbb{M} 关于乘积空间上的 Lebesgue 测度有密度 m 。密度 p 可以看成是 \mathcal{X} 上的一些初始的质量分布, 而密度 q 则可以看成是一些想要得到的分布, 我们的目标是对质量进行传输, 从而将初始分布 p 变换为想要的分布 q 。 $\rho(x, x') dx dx'$ 可以理解为将一个质量的小增量 dx 传输到新的增量 dx' 的损失, 联合密度 $m(x, x')$ 称为传输计划, 是一个将 p 转换成 q 的质量变换体系, 则计划 m 对应的传输成本为

$$\int_{\mathcal{X} \times \mathcal{X}} \rho(x, x') m(x, x') dx dx',$$

取下确界就是 Wasserstein 距离。

3.3.2 传输成本和集中不等式

给定两个分布 \mathbb{Q}, \mathbb{P} , 两者之间的 **Kullback-Leibler(KL) 散度**为

$$D(\mathbb{Q} \parallel \mathbb{P}) := \begin{cases} \mathbb{E}_{\mathbb{Q}} \left[\log \frac{d\mathbb{Q}}{d\mathbb{P}} \right], & \mathbb{Q} \text{ 关于 } \mathbb{P} \text{ 绝对连续} \\ +\infty, & \text{否则} \end{cases} \quad (3.28)$$

如果对某个测度 ν , 这些分布有密度 q, p , 那么 KL 散度可以写成

$$D(\mathbb{Q} \parallel \mathbb{P}) = \int_{\mathcal{X}} q(x) \log \frac{q(x)}{p(x)} \nu(dx). \quad (3.29)$$

传输成本不等式指的是 Wasserstein 距离能被 KL 散度平方根的一个倍数所控制。

定义 3.2 (传输成本不等式)

对于一个给定的度量 ρ , 概率测度 \mathbb{P} 称作满足参数为 $\gamma > 0$ 的 ρ 传输成本不等式, 如果

对任意概率测度 \mathbb{Q} 有

$$W_\rho(\mathbb{Q}, \mathbb{P}) \leq \sqrt{2\gamma D(\mathbb{Q} \parallel \mathbb{P})}. \quad (3.30)$$

由于 KL 散度在信息论中非常重要，这个结果也被称为**信息不等式**。

由 Wasserstein 距离的定义，传输成本不等式 (3.30) 可以通过 KL 散度 $D(\mathbb{Q} \parallel \mathbb{P})$ 来控制偏差 $\int f d\mathbb{Q} - \int f d\mathbb{P}$ 的上界。因此，可以选取一个特定的分布 \mathbb{Q} 来推导 \mathbb{P} 下 f 的集中度界。

定理 3.8 (从传输成本到集中度)

考虑一个度量测度空间 $(\mathbb{P}, \mathcal{X}, \rho)$ ，假设 \mathbb{P} 满足 ρ 传输成本不等式 (3.30)，那么它的集中度满足界

$$\alpha_{\mathbb{P},(X,\rho)}(t) \leq 2 \exp\left(-\frac{t^2}{2\gamma}\right). \quad (3.31)$$

进一步，对任意 $X \sim \mathbb{P}$ 和任意 L -Lipschitz 函数 $f: \mathcal{X} \rightarrow \mathbb{R}$ ，有集中不等式

$$\mathbb{P}[|f(X) - \mathbb{E}[f(X)]| \geq t] \leq 2 \exp\left(-\frac{t^2}{2\gamma L^2}\right). \quad (3.32)$$

证明 略。

□

3.3.3 传输成本的张量化

命题 3.9

假设对每个 $k = 1, \dots, n$ ，单变量分布 \mathbb{P}_k 满足参数为 γ_k 的 ρ_k 传输成本不等式，那么乘积分布 $\mathbb{P} = \bigotimes_{k=1}^n \mathbb{P}_k$ 满足传输成本不等式

$$W_\rho(\mathbb{Q}, \mathbb{P}) \leq \sqrt{2 \left(\sum_{k=1}^n \gamma_k \right) D(\mathbb{Q} \parallel \mathbb{P})}, \quad \text{对所有分布 } \mathbb{Q}, \quad (3.33)$$

其中 Wasserstein 度量的定义基于距离 $\rho(x, y) := \sum_{k=1}^n \rho_k(x_k, y_k)$ 。

证明 略。

□

例 3.5 (有界差不等式)

设 f 满足有界差性质 (2.24)，由三角不等式， f 是 1-Lipschitz 函数，对应的是重尺度化 Hamming 度量 $\rho(\mathbf{x}, \mathbf{y}) = \sum_{k=1}^n \rho_k(x_k, y_k)$ ，其中 $\rho_k(x_k, y_k) := L_k \mathbb{I}[x_k \neq y_k]$ 。

由 Pinsker-Csiszár-Kullback 不等式，每个单变量分布 \mathbb{P}_k 满足参数为 $\gamma_k = \frac{L_k^2}{4}$ 的 ρ_k 传输

成本不等式，由命题 3.9， $\mathbb{P} = \bigotimes_{k=1}^n \mathbb{P}_k$ 满足参数为 $\gamma = \frac{1}{4} \sum_{k=1}^n L_k^2$ 的 ρ 传输成本不等式。

因为 f 在度量 ρ 下是 1-Lipschitz 的，由定理 3.8 知

$$\mathbb{P}[|f(X) - \mathbb{E}[f(X)]| \geq t] \leq 2 \exp\left(-\frac{2t^2}{\sum_{k=1}^n L_k^2}\right), \quad \forall t \geq 0. \quad (3.34)$$

3.3.4 马尔可夫链的传输成本不等式

设 (X_1, \dots, X_n) 是一个由马尔可夫链产生的随机向量，其中每个 X_i 在可数空间 \mathcal{X} 上取值。其在 \mathcal{X}^n 上的分布 \mathbb{P} 由一个初始分布 $X_1 \sim \mathbb{P}_1$ 和转移核函数

$$\mathbb{K}_{i+1}(x_{i+1} | x_i) = \mathbb{P}_{i+1}(X_{i+1} = x_{i+1} | X_i = x_i) \quad (3.35)$$

定义。考虑离散空间上 β 收缩的马尔可夫链，即存在 $\beta \in [0, 1)$ 满足

$$\max_{i=1, \dots, n-1} \sup_{x_i, x'_i} \|\mathbb{K}_{i+1}(\cdot | x_i) - \mathbb{K}_{i+1}(\cdot | x'_i)\|_{\text{TV}} \leq \beta. \quad (3.36)$$

定理 3.10

令 \mathbb{P} 是离散空间 \mathcal{X}^n 上的一个 β 收缩的马尔可夫链的分布函数，那么对于 \mathcal{X}^n 上的任意其他分布 \mathbb{Q} ，有

$$W_\rho(\mathbb{Q}, \mathbb{P}) \leq \frac{1}{1-\beta} \sqrt{\frac{n}{2} D(\mathbb{Q} \| \mathbb{P})}, \quad (3.37)$$

其中 Wasserstein 距离是基于 Hamming 范数 $\rho(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^n \mathbb{I}[x_i \neq y_i]$ 定义的。

3.3.5 非对称耦合成本

和定理 2.10 的结果类似，基于 ℓ_2 范数的 Lipschitz 条件通常可以导出独立于维数的结果。

定理 3.11

考虑一个独立随机变量的向量 (X_1, \dots, X_n) ，每个都在 $[0, 1]$ 上取值。设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是凸的，并在欧几里得范数下是 L -Lipschitz 的，则有

$$\mathbb{P}[|f(\mathbf{X}) - \mathbb{E}[f(\mathbf{X})]| \geq t] \leq 2 \exp\left(-\frac{t^2}{2L^2}\right), \quad \forall t \geq 0. \quad (3.38)$$

证明 略。 □

例 3.6 (回顾 Rademacher 复杂度)

由上述定理，可以得到 Rademacher 复杂度更精细的界

$$\mathbb{P}[|Z - \mathbb{E}[Z]| \geq t] \leq 2 \exp\left(-\frac{t^2}{2W^2(\mathcal{A})}\right). \quad (3.39)$$

3.4 经验过程的尾部概率界

本节我们使用熵方法来推导经验过程上确界的多种尾部概率界。

设 \mathcal{F} 为一类函数 $f: \mathcal{X} \rightarrow \mathbb{R}$, 设 (X_1, \dots, X_n) 来自一个乘积分布 $\mathbb{P} = \bigotimes_{i=1}^n \mathbb{P}_i$, 其中每个 \mathbb{P}_i 以某个 $\mathcal{X}_i \subset \mathcal{X}$ 为支撑集。考虑随机变量

$$Z = \sup_{f \in \mathcal{F}} \left\{ \frac{1}{n} \sum_{i=1}^n f(X_i) \right\}, \quad (3.40)$$

这一节的主要目标是推导关于尾事件 $\{Z \geq \mathbb{E}[Z] + \delta\}$ 的上界。

3.4.1 一个泛函 Hoeffding 不等式

定理 3.12 (泛函 Hoeffding 定理)

对于每个 $f \in \mathcal{F}$ 和 $i = 1, \dots, n$, 假设存在实数 $a_{i,f} \leq b_{i,f}$, 对 $\forall x \in \mathcal{X}_i$, 满足 $f(x) \in [a_{i,f}, b_{i,f}]$, 那么对 $\forall \delta \geq 0$, 有

$$\mathbb{P}[Z \geq \mathbb{E}[Z] + \delta] \leq \exp\left(-\frac{n\delta^2}{4L^2}\right), \quad (3.41)$$

$$\text{其中 } L^2 := \sup_{f \in \mathcal{F}} \left\{ \frac{1}{n} \sum_{i=1}^n (b_{i,f} - a_{i,f})^2 \right\}.$$

证明 略。

□

3.4.2 一个泛函 Bernstein 不等式

定理 3.13 (经验过程的 Talagrand 集中度)

考虑一个被 b 一致控制的可数函数类 \mathcal{F} , 那么对 $\forall \delta > 0$, 随机变量 Z 满足上尾部概率界

$$\mathbb{P}[Z \geq \mathbb{E}[Z] + \delta] \leq 2 \exp\left(\frac{-n\delta^2}{8e\mathbb{E}[\Sigma^2] + 4b\delta}\right), \quad (3.42)$$

$$\text{其中 } \Sigma^2 = \sup_{f \in \mathcal{F}} \left\{ \frac{1}{n} \sum_{i=1}^n f^2(X_i) \right\}.$$

证明 略。

□

第 4 章 一致大数定律

第 5 章 2024 高维期末范围

第 2 章

例 5.1 (习题 2.4: 有界随机变量紧的次高斯参数)

考虑一个均值为 $\mu = \mathbb{E}[X]$ 的随机变量 X , 满足 $X \in [a, b]$, a.s.。

(a) 定义函数 $\psi(\lambda) = \log \mathbb{E}[e^{\lambda X}]$, 证明: $\psi(0) = 0$ 且 $\psi'(0) = \mu$ 。

(b) 证明 $\psi''(\lambda) = \mathbb{E}_\lambda[X^2] - (\mathbb{E}_\lambda[X])^2$, 其中 $\mathbb{E}_\lambda[f(X)] := \frac{\mathbb{E}[f(X)e^{\lambda X}]}{\mathbb{E}[e^{\lambda X}]}$, 并由此得到一个 $\sup_{\lambda \in \mathbb{R}} |\psi''(\lambda)|$ 的上界。

(c) 用 (a) 和 (b) 证明 X 是次高斯的, 且参数至多为 $\sigma = \frac{b-a}{2}$ 。

证明 易证。由 X 的有界性可得 $|\psi''(\lambda)| = \text{Var}_\lambda(X) \leq \left(\frac{b-a}{2}\right)^2$ 。 \square

例 5.2 (习题 2.5: 次高斯界和均值方差)

设随机变量 X 满足

$$\mathbb{E}[e^{\lambda X}] \leq \exp\left(\frac{\lambda^2 \sigma^2}{2} + \lambda \mu\right), \quad \forall \lambda \in \mathbb{R}.$$

(a) 证明 $\mathbb{E}[X] = \mu$ 。

(b) 证明 $\text{Var}(X) \leq \sigma^2$ 。

(c) 假设 σ 的取值是使条件中的不等式成立的最小的 σ , 那么 $\text{Var}(X) = \sigma^2$ 是否成立?

证明 (a)(b) 泰勒展开分别令 $\lambda \rightarrow 0^+$ 和 $\lambda \rightarrow 0^-$ 即可。

(c) 否, 反例考虑以较小概率取较大值的随机变量, 如 Bernoulli(1, p) 中取 $p = \frac{1}{4}$ 。 \square

例 5.3 (习题 2.11: 正态随机变量最大值的上下界)

设 $\{X_i\}_{i=1}^n$ 为 i.i.d. 的 $\mathcal{N}(0, \sigma^2)$ 随机变量序列, 考虑随机变量 $Z_n := \max_{i=1, \dots, n} |X_i|$ 。

(a) 证明

$$\mathbb{E}[Z_n] \leq \sqrt{2\sigma^2 \log n} + \frac{4\sigma}{\sqrt{2 \log n}}, \quad \forall n \geq 2.$$

(提示: 标准正态随机变量的尾部概率不等式 $\mathbb{P}[U \geq \delta] \leq \sqrt{\frac{2}{\pi}} \frac{1}{\delta} e^{-\delta^2/2}$)

(b) 证明

$$\mathbb{E}[Z_n] \geq (1 - 1/e) \sqrt{2\sigma^2 \log n}, \quad \forall n \geq 5.$$

(c) 证明 $\frac{\mathbb{E}[Z_n]}{\sqrt{2\sigma^2 \log n}} \rightarrow 1$ 当 $n \rightarrow \infty$ 。

证明 (a) 记 $c = \sqrt{2 \log n}$, 则

$$\begin{aligned}\mathbb{E}[Z_n] &= \int_0^\infty \mathbb{P}[Z_n \geq t] dt \leq c + \int_c^\infty \mathbb{P}[Z_n \geq t] dt \\ &\leq c + 2n \int_c^\infty \mathbb{P}[X_1 \geq t] dt \leq c + 4n \int_c^\infty \frac{1}{\sqrt{2\pi}} t^{-1} e^{-t^2/2} dt \\ &\leq c + \frac{4n}{c} \int_c^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt \\ &= c + \frac{4}{c} [n(1 - \Phi(c))]\end{aligned}$$

由 $n(1 - \Phi(\sqrt{2 \log n})) \leq 1$ 即证。

(b)(c) ???

□

例 5.4 (习题 2.12: 次高斯随机变量最大值的上界)

设 $\{X_i\}_{i=1}^n$ 为均值为 0, 参数为 σ 的次高斯随机变量序列 (不要求独立性)。

(a) 证明

$$\mathbb{E} \left[\max_{i=1, \dots, n} X_i \right] \leq \sqrt{2\sigma^2 \log n}, \quad \forall n \geq 1.$$

(提示: 指数函数为凸函数)

(b) 证明随机变量 $Z := \max_{i=1, \dots, n} |X_i|$ 满足

$$\mathbb{E}[Z] \leq \sqrt{2\sigma^2 \log(2n)} \leq 2\sqrt{\sigma^2 \log n}, \quad \forall n \geq 2.$$

证明

(a) 由 Jensen 不等式, 对 $\forall \lambda > 0$

$$\exp \left(\lambda \mathbb{E} \left[\max_{1 \leq i \leq n} X_i \right] \right) \leq \mathbb{E} \left[\max_{1 \leq i \leq n} e^{\lambda X_i} \right] \leq \sum_{i=1}^n \mathbb{E} [e^{\lambda X_i}] \leq n e^{\frac{\lambda^2 \sigma^2}{2}},$$

从而

$$\mathbb{E} \left[\max_{1 \leq i \leq n} X_i \right] \leq \inf_{\lambda > 0} \left\{ \frac{\log n}{\lambda} + \frac{\lambda \sigma^2}{2} \right\} = \sqrt{2\sigma^2 \log n}.$$

(b) 记 $Y_i = X_i, Y_{n+1} = -X_i, i = 1, \dots, n$, 则 $Z = \mathbb{E} \left[\max_{1 \leq i \leq 2n} Y_i \right]$, 由 (a) 易证。

□

例 5.5 (习题 2.14: 中位数和均值的集中不等式)

给定一元随机变量 X , 假设存在正常数 c_1, c_2 满足

$$\mathbb{P}[|X - \mathbb{E}[X]| \geq t] \leq c_1 e^{-c_2 t^2}, \quad \forall t \geq 0.$$

(a) 证明: $\text{Var}(X) \leq \frac{c_1}{c_2}$ 。

(b) 设中位数 m_X 是任意满足 $\mathbb{P}[X \geq m_X] \geq 1/2$ 和 $\mathbb{P}[X \leq m_X] \geq 1/2$ 的数, 给出一个中位数不唯一的例子。

(c) 证明只要均值的集中不等式成立, 那么对任意中位数 m_X , 也有集中不等式成立

$$\mathbb{P}[|X - m_X| \geq t] \leq c_3 e^{-c_4 t^2}, \quad \forall t \geq 0,$$

其中 $c_3 = 4c_1, c_4 = \frac{c_2}{8}$ 。

(d) 反过来, 证明只要关于中位数的集中不等式成立, 那么均值的集中不等式也成立, 对应的参数为 $c_1 = 2c_3, c_2 = \frac{c_4}{4}$ 。

证明

(a)

$$\text{Var}(X) = \int_0^\infty \mathbb{P}((X - \mu)^2 > t) dt \leq c_1 \int_0^\infty e^{-c_2 t} dt = \frac{c_1}{c_2}.$$

(b) Rademacher 随机变量显然满足要求。

(c) 记 $\Delta = |\mu_X - m_X|$, 引入待定参数 $\alpha > 0$, 对 $t > \alpha\Delta$, 有

$$\begin{aligned} \mathbb{P}(|X - m_X| \geq t) &= \mathbb{P}\left(|X - m_X| \geq \frac{t}{\alpha} + \left(1 - \frac{1}{\alpha}\right)t\right) \\ &\leq \mathbb{P}\left(|X - m_X| \geq \Delta + \left(1 - \frac{1}{\alpha}\right)t\right) \\ &\leq \mathbb{P}\left(|X - \mu_X| \geq \left(1 - \frac{1}{\alpha}\right)t\right) \leq c_1 e^{-c_2(1-\alpha^{-1})^2 t^2}. \end{aligned}$$

对 $0 \leq t \leq \alpha\Delta$, 再引入待定参数 $\beta > 1$, 我们希望下式成立

$$\beta c_1 e^{-c_2(1-\alpha^{-1})^2 t^2} \geq \beta c_1 e^{-c_2(\alpha-1)^2 \Delta^2} \geq 1 \geq \mathbb{P}(|X - m_X| \geq t).$$

因此, 需要估计 Δ 的上界。由

$$\begin{aligned} \mathbb{P}(X \geq \mathbb{E}[X] + t) &\leq c_1 e^{-c_2 t^2}, \\ \mathbb{P}(X \leq \mathbb{E}[X] - t) &\leq c_1 e^{-c_2 t^2}, \end{aligned}$$

如果 $\mu_X + t$ 或 $\mu_X - t$ 为中位数, 则必有 $c_1 e^{-c_2 t^2} \geq \frac{1}{2}$, 从而知 $\Delta \leq \sqrt{\frac{1}{c_2} \log(2c_1)}$ 。为使下式成立

$$\beta c_1 e^{-c_2(\alpha-1)^2 \Delta^2} \geq \beta c_1 e^{-(\alpha-1)^2 \log 2c_1} = \beta c_1 \left(\frac{1}{2c_1}\right)^{(\alpha-1)^2} \geq 1.$$

取 $\alpha = 2$ 和 $\beta = 2$ 即可。进而可得结论对 $c_3 = 2c_1, c_4 = \frac{c_2}{4}$ 成立。

(d) ???

□

例 5.6 (习题 2.15: 集中度和核密度估计)

设 $\{X_i\}_{i=1}^n$ 是密度函数为 f 的独立同分布随机变量序列, 密度函数 f 的一个标准估计是核密度估计

$$\hat{f}_n(x) := \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right),$$

其中 $K: \mathbb{R} \rightarrow [0, \infty)$ 是满足 $\int_{-\infty}^{\infty} K(t) dt = 1$ 的核函数, $h > 0$ 为窗宽参数。考虑用 L_1

范数 $\|\hat{f}_n - f\|_1 := \int_{-\infty}^{\infty} |\hat{f}_n(t) - f(t)| dt$ 来评估统计量 \hat{f}_n , 证明:

$$\mathbb{P} \left(\|\hat{f}_n - f\|_1 \geq \mathbb{E} [\|\hat{f}_n - f\|_1] + \delta \right) \leq e^{-\frac{n\delta^2}{8}}.$$

证明 记 $g(x_1, \dots, x_n) = \|\hat{f}_n - f\|_1$, 则 g 满足参数为 $L_k = \frac{2}{n}$ 的有界差性质, 由推论 2.9 可得更优的上界为 $e^{-\frac{1}{2}nt^2}$. \square

第 3 章

例 5.7 (习题 3.2: 链式法则和 Kullback-Leibler 散度)

给定两个 n 元分布 \mathbb{Q} 和 \mathbb{P} , 证明 Kullback-Leibler 散度可以被分解为

$$D(\mathbb{Q} \parallel \mathbb{P}) = D(\mathbb{Q}_1 \parallel \mathbb{P}_1) + \sum_{j=2}^n \mathbb{E}_{\mathbb{Q}_1^{j-1}} [D(\mathbb{Q}_j(\cdot | X_1^{j-1}) \parallel \mathbb{P}_j(\cdot | X_1^{j-1}))],$$

其中 $\mathbb{Q}_j(\cdot | X_1^{j-1})$ 为在 \mathbb{Q} 下给定 (X_1, \dots, X_{j-1}) 时 X_j 的条件分布, $\mathbb{P}_j(\cdot | X_1^{j-1})$ 类似。

证明 由定义得,

$$\begin{aligned} D(\mathbb{Q} \parallel \mathbb{P}) &= \int \log \frac{q(x_1^n)}{p(x_1^n)} q(x_1^n) \nu(dx_1^n) = \int \log \frac{q_n(x_n | x_1^{n-1}) \cdots q_2(x_2 | x_1) q_1(x_1)}{p_n(x_n | x_1^{n-1}) \cdots p_2(x_2 | x_1) p_1(x_1)} q(x_1^n) \nu(dx_1^n) \\ &= \int \log \frac{q_1(x_1)}{p_1(x_1)} q(x_1) \nu(dx_1) + \sum_{j=2}^n \int \log \frac{q_j(x_j | x_1^{j-1})}{p_j(x_j | x_1^{j-1})} q(x_1^n) \nu(dx_1^n) \\ &= D(\mathbb{Q}_1 \parallel \mathbb{P}_1) + \sum_{j=2}^n \int \left[\int \log \frac{q_j(x_j | x_1^{j-1})}{p_j(x_j | x_1^{j-1})} q_j(x_j | x_1^{j-1}) \nu(dx_j) \right] q(x_1^{j-1}) \nu(dx_1^{j-1}) \\ &= D(\mathbb{Q}_1 \parallel \mathbb{P}_1) + \sum_{j=2}^n \mathbb{E}_{\mathbb{Q}_1^{j-1}} [D(\mathbb{Q}_j(\cdot | X_1^{j-1}) \parallel \mathbb{P}_j(\cdot | X_1^{j-1}))]. \end{aligned}$$

\square

例 5.8 (习题 3.7: 有界变量的熵)

设 $X \in [a, b]$, a.s. 是均值为 0 的随机变量, 证明 $\mathbb{H}(e^{\lambda X}) \leq \frac{\lambda^2 \sigma^2}{2} \varphi_X(\lambda)$, 其中 $\sigma = \frac{b-a}{2}$. (提示: 可以利用习题 3.3 的结果, 熵有变分表示 $\mathbb{H}(e^{\lambda X}) = \inf_{t \in \mathbb{R}} \mathbb{E} [\psi(\lambda(X-t)) e^{\lambda X}]$, 其中 $\psi(u) := e^{-u} - 1 + u$.)

证明 由 $\psi(u) \leq \frac{u^2}{2}, \forall u > 0$, 在熵的变分表示中令 $t = a$ 得,

$$\mathbb{H}(e^{\lambda X}) \leq \psi(\lambda(b-a)) \varphi_X(\lambda) \leq \frac{1}{2} \lambda^2 (b-a)^2 \varphi_X(\lambda),$$

该结果和结论相差一个系数。 \square

例 5.9 (习题 3.9: 熵的另一种变分表示)

证明熵的下列变分表达形式

$$\mathbb{H}(e^{\lambda f(X)}) = \sup_g \{ \mathbb{E}[g(X)e^{\lambda f(X)}] : \mathbb{E}[e^{g(X)}] \leq 1 \},$$

其中上确界在所有可测函数上取, 并给出一个函数 g 使得上确界被取到。

证明 设函数 g 满足 $\mathbb{E}[e^{g(X)}] \leq 1$, 记 \mathbb{E}_g 为在密度函数 $\frac{e^{g(x)}f_X(x)}{\mathbb{E}[e^{g(X)}]}$ 下求期望, 则有

$$\begin{aligned}
& \mathbb{H}(e^{\lambda f(X)}) - \mathbb{E}[g(X)e^{\lambda f(X)}] \\
&= \mathbb{E}[(\lambda f(X) - g(X))e^{\lambda f(X)}] - \mathbb{E}[e^{\lambda f(X)}] \log \mathbb{E}[e^{\lambda f(X)}] \\
&= \mathbb{E}[e^{g(X)}] \{ \mathbb{E}_g[(\lambda f(X) - g(X))e^{\lambda f(X)-g(X)}] - \mathbb{E}_g[e^{\lambda f(X)-g(X)}] \log (\mathbb{E}[e^{g(X)}]\mathbb{E}_g[e^{\lambda f(X)-g(X)}]) \} \\
&\geq \mathbb{E}[e^{g(X)}] \{ \mathbb{E}_g[(\lambda f(X) - g(X))e^{\lambda f(X)-g(X)}] - \mathbb{E}_g[e^{\lambda f(X)-g(X)}] \log \mathbb{E}_g[e^{\lambda f(X)-g(X)}] \} \\
&= \mathbb{E}[e^{g(X)}] \cdot \mathbb{H}_g(e^{\lambda f(X)-g(X)}) \geq 0
\end{aligned}$$

由上述证明过程知, 取 $g(x) = \lambda f(x) - \log \mathbb{E}[e^{\lambda f(X)}]$ 时等号成立, 故结论得证。 \square

例 5.10 (习题 3.13: 全变差和 Wasserstein 距离)

考虑基于 Hamming 度量的 Wasserstein 距离, 即 $W_\rho(\mathbb{P}, \mathbb{Q}) = \inf_{\mathbb{M}} \mathbb{M}[X \neq Y]$, 其中下确界在所有耦合 \mathbb{M} 上取。证明:

$$\inf_{\mathbb{M}} \mathbb{M}[X \neq Y] = \|\mathbb{P} - \mathbb{Q}\|_{\text{TV}} = \sup_{A \subseteq \mathcal{X}} |\mathbb{P}(A) - \mathbb{Q}(A)|,$$

其中上确界在 \mathcal{X} 的所有可测子集 A 上取。

证明 思路: 分别证明 $\|\mathbb{P} - \mathbb{Q}\|_{\text{TV}} = \sup_{f: \mathcal{X} \rightarrow [0,1]} \int f(d\mathbb{P} - d\mathbb{Q})$ 和 $W_\rho(\mathbb{P}, \mathbb{Q}) = \sup_{f: \mathcal{X} \rightarrow [0,1]} \int f(d\mathbb{P} - d\mathbb{Q})$, 从而得到 $\|\mathbb{P} - \mathbb{Q}\|_{\text{TV}} = W_\rho(\mathbb{P}, \mathbb{Q})$ 。 \square

第 4 章

附录 A 常用分布表

分 布 名 称	概 率 密 度	期 望	方 差	特 征 函 数
退化分布	$\begin{pmatrix} c \\ 1 \end{pmatrix}$	c	0	e^{ict}
Bernoulli 分布	$\begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}$	p	pq	$q + pe^{it}$
二项分布 $B(n, p)$	$\begin{pmatrix} n \\ k \end{pmatrix} p^k q^{n-k},$ $k = 0, 1, \dots, n$	np	npq	$(q + e^{it})^n$
几何分布 $G(p)$	$q^{k-1}p,$ $k = 1, 2, \dots$	$\frac{1}{p}$	$\frac{q}{p^2}$	$\frac{pe^{it}}{1 - qe^{it}}$
Pascal 分布 (负二项分布)	$\begin{pmatrix} k-1 \\ r-1 \end{pmatrix} p^r q^{k-r},$ $k = r, r+1, \dots$	$\frac{r}{p}$	$\frac{rq}{p^2}$	$\left(\frac{pe^{it}}{1 - qe^{it}} \right)^r$
超几何分布	$\frac{\begin{pmatrix} M \\ k \end{pmatrix} \begin{pmatrix} N-M \\ n-k \end{pmatrix}}{\begin{pmatrix} N \\ n \end{pmatrix}},$ $k = 0, 1, \dots, n$	$\frac{nM}{N}$	$\frac{nM}{N} \left(1 - \frac{M}{N} \right) \frac{N-n}{N-1}$	
Poisson 分布 $P(\lambda)$	$\frac{\lambda^k}{k!} e^{-\lambda},$ $k = 0, 1, 2, \dots$	λ	λ	$e^{\lambda(e^{it}-1)}$
均匀分布 $U(a, b)$	$\frac{1}{b-a},$ $a < x < b$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	$\frac{e^{itb} - e^{ita}}{it(b-a)}$
正态分布 $N(a, \sigma^2)$	$\frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(x-a)^2}{2\sigma^2}},$ $-\infty < x < +\infty$	a	σ^2	$e^{iait - \frac{1}{2}\sigma^2 t^2}$

分布名称	概率密度	期望	方差	特征函数
指数分布	$\lambda e^{-\lambda x},$ $x > 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	$(1 - \frac{it}{\lambda})^{-1}$
Γ 分布 $\Gamma(\lambda, r)$	$\frac{\lambda^r}{\Gamma(r)} x^{r-1} e^{-\lambda x},$ $x > 0$	$\frac{r}{\lambda}$	$\frac{r}{\lambda^2}$	$(1 - \frac{it}{\lambda})^{-r}$
χ^2 分布 $\chi^2(n)$	$\frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} x^{\frac{n}{2}-1} e^{-\frac{x}{2}},$ $x > 0$	n	$2n$	$(1 - 2it)^{-\frac{n}{2}}$
Cauchy 分布 $C(\lambda, \mu)$	$\frac{1}{\pi} \frac{\lambda}{\lambda^2 + (x - \mu)^2},$ $-\infty < x < +\infty$	不存在	不存在	$e^{i\mu t - \lambda t }$
Rayleigh 分布	$\frac{x}{\sigma^2} e^{-\frac{x^2}{2\sigma^2}},$ $x > 0$	$\sqrt{\frac{\pi}{2}} \sigma$	$(2 - \frac{\pi}{2}) \sigma^2$	
对数正态分布	$\frac{1}{\sigma x \sqrt{2\pi}} e^{-\frac{(\ln x - \mu)^2}{2\sigma^2}},$ $x > 0$	$e^{a + \frac{\sigma^2}{2}}$	$e^{2a + \sigma^2} (e^{\sigma^2} - 1)$	
Weibull 分布	$\alpha \lambda x^{\alpha-1} e^{-\lambda x^\alpha},$ $x > 0$	$\Gamma(\frac{1}{\alpha} + 1) \lambda^{-\frac{1}{\alpha}}$	$\lambda^{-\frac{2}{\alpha}} [\Gamma(\frac{2}{\alpha} + 1) - (\Gamma(\frac{1}{\alpha} + 1))^2]$	
Laplace 分布	$\frac{1}{2\lambda} e^{-\frac{ x-\mu }{\lambda}},$ $-\infty < x < +\infty$	μ	$2\lambda^2$	$\frac{e^{i\mu t}}{1 + \lambda^2 t^2}$
t 分布 $t(n)$	$\frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi} \Gamma(\frac{n}{2})} (1 + \frac{x^2}{n})^{-\frac{n+1}{2}},$ $-\infty < x < +\infty$	0 ($n > 1$)	$\frac{n}{n-2}$ ($n > 2$)	
F 分布 $F(m, n)$	$\frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2}) \Gamma(\frac{n}{2})} m^{\frac{m}{2}} n^{\frac{n}{2}} x^{\frac{m}{2}-1} (n+mx)^{-\frac{m+n}{2}}, x > 0$	$\frac{n}{n-2}$ ($n > 2$)	$\frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}$ ($n > 4$)	
贝塔分布	$\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1},$ $0 < x < 1$	$\frac{\alpha}{\alpha + \beta}$	$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$	

索引

L -Lipschitz, 10, 16

U 统计量, 9

β 收缩的马尔可夫链, 19

ℓ_2 算子范数, 11

ϵ 扩张, 15

ϕ 熵, 12

Azuma-Hoeffding 不等式, 8

Bernstein 不等式, 5

Bernstein 型界, 5

Bernstein 条件, 4

Bernstein 熵的界, 13

Chebyshev 不等式, 2

Chernoff 界, 2

Doob 鞅, 7

Frobenius 范数, 11

Herbst 方法, 13

Hoeffding 界, 3

Kullback-Leibler 散度, 17

Rademacher 复杂度, 9

Rademacher 定理, 14

Rademacher 随机变量, 2

Wasserstein 度量, 16

上偏差 inequality, 2

传输成本, 17

传输成本不等式, 17

信息不等式, 18

全变差距离, 17

可分凸函数, 13

域流, 7

对偶理论, 17

对称化技巧, 3

度量测度空间, 15

强凸函数, 16

强对数凹分布, 16

有界差不等式, 8

条件熵, 14

次指数随机变量, 4

次高斯随机变量, 2

次高斯参数, 2

熵的张量化, 14

耦合, 17

集中不等式, 2

集中度函数, 15

鞅, 7

鞅差序列, 7

马尔可夫不等式, 2

高斯复杂度, 11

参考文献

- [1] Wainwright M J. High-dimensional Statistics: A Non-Asymptotic Viewpoint: vol. 48. Cambridge university press, 2019.
- [2] 王成, 刘卫东. 高维统计学: 非渐进视角. 机械工业出版社, 2023.